

WYKŁAD 2: WPROWADZENIE DO SZTUCZNYCH SIECI NEURONOWYCH



S. Hoa Nguyen

Katedra: Systemy Inteligentne

hoa@pjwstk.edu.pl

<http://www.users.pjwstk.edu.pl/~hoa/www/>

Narzędzie Sztucznej Inteligencji

PLAN WYKŁADU

- Wprowadzenie w tematykę sieci neuronowych
- Neuron sztuczny odpowiednik neuronu biologicznego
- Architektury sieci
- Uczenie perceptronu



HISTORIA

- Początki
 - 1943 – W.McCulloch, W.Pitts – pierwszy formalny model neuronu;
 - 1949 – Donald Hebb – „The organization of behaviour” – reguła uaktualniania wag połączeń neuronów.
- Pierwsze sukcesy
 - 1957-58 – F.Rosenblatt, Ch. Wightman – PERCEPTRON;
 - 1960 – B.Widrow, M.Hoff – ADALINE;

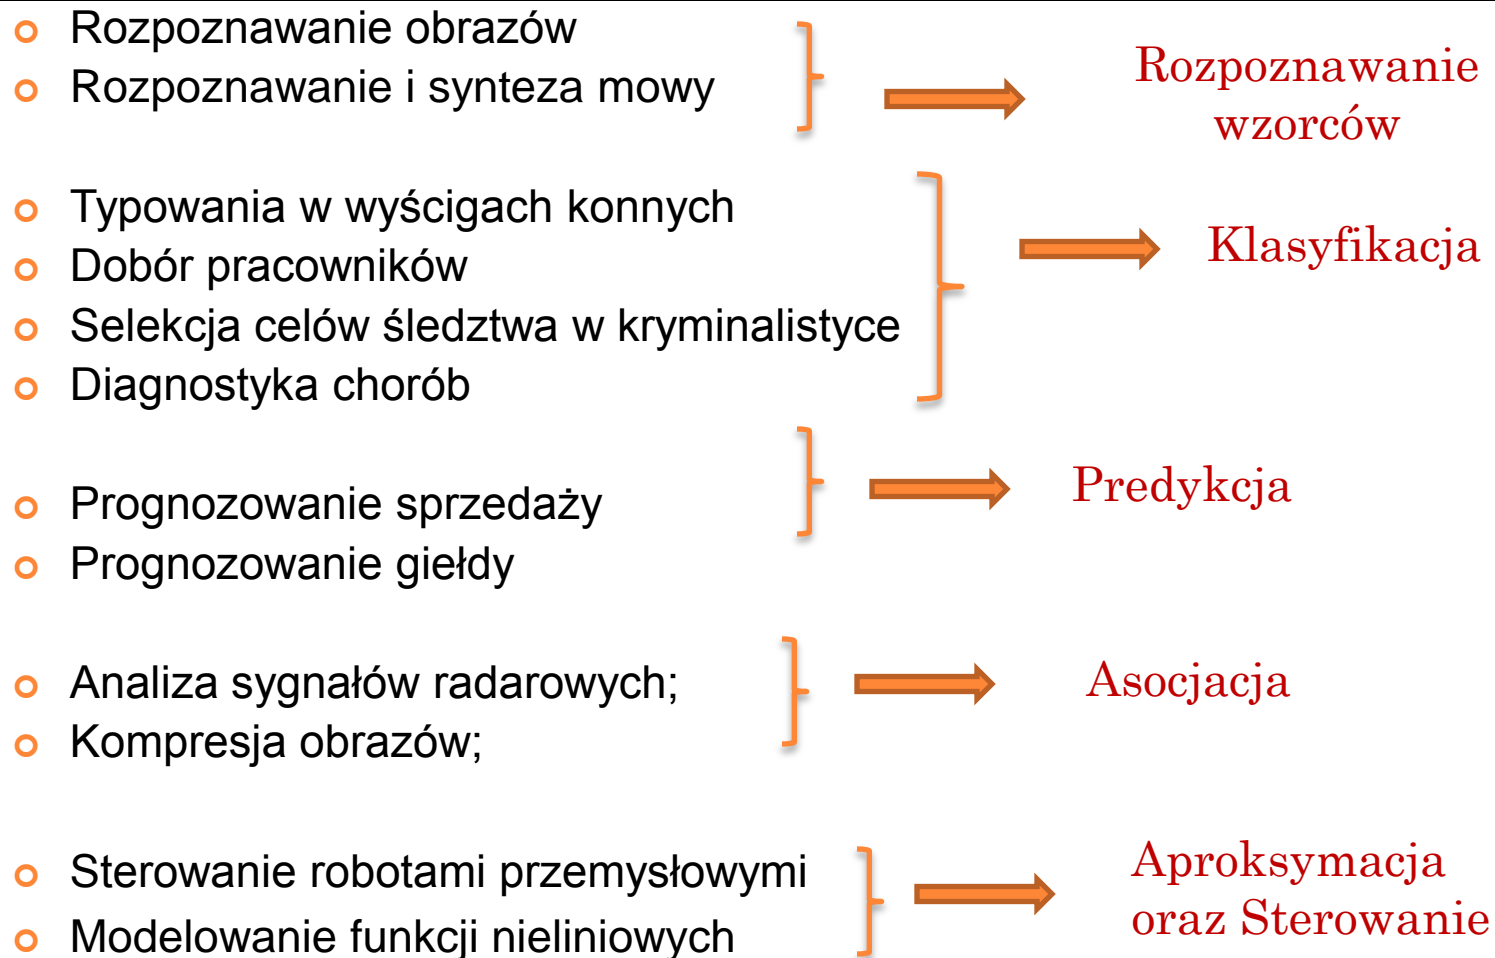


HISTORIA

- Okres zastoju
 - 1969 – M.Minsky, S.Papert – publikacja „Perceptrons”
 - 1972-82 - T.Kohonen – pamięć skojarzeniowa
 - 1974,82 – S.Grossberg, G.Carpenter – teoria sieci rezonansowych.
- Ponowny rozkwit
 - 1983-86 – prace Johna Hopfielda;
 - 1986 - James McClelland, David Rumelhard „Parallel Distributed Processing” – „odkrycie” metody uczenia perceptronów wielowarstwowych.




FUNKCJE SIECI NEURONOWYCH I ZASTOSOWANIA



MÓZG – INSPIRACJA NEUROFIZJOLOGICZNA


- Liczba połączeń synaptycznych w mózgu: $10^{10} - 10^{11}$;
 - Gęstość połączeń synaptycznych: $\sim 10^4/\text{neuron}$
 - Częstość generacji sygnałów przez neuron: $\sim 1 - 100 \text{ Hz}$;
 - Szybkość pracy: $\sim 10^{18}$ operacji/s
- (najszybsze komputery: $\sim 10^{12}$ operacji/s)



- Odporny na uszkodzenia;
- Elastyczny – łatwo dostosowuje się do zmiennego otoczenia;
- Uczy się – nie musi być programowany
- Potrafi radzić sobie z informacją rozmytą, zaszumioną lub niespójną;
- W wysokim stopniu równoległy;



NEURON BIOLOGICZNY I JEGO FUNKCJONOWANIE



Jądro - "centrum obliczeniowe" neuronu.

Akson - "wyjście" neuronu.

Wzgórek aksonu - stąd wysyłany jest sygnał wyjściowy.



Dendryt – „wejście” neuronu.

Synapsa - . Może ona zmienić moc sygnału napływającego poprzez dendryt.

- **Potencjały** odebrane z innych komórek za pomocą dendrytów są zbierane na błonie ciała komórki.
- Gdy zebrane potencjały przekroczą **wartość progową** neuron staje się aktywny i wysyła sygnały elektryczne (elektrochemiczne) przez akson.
- Inne neurony odbierają sygnał zależnie od **przepustowości synaps**.




MODEL SZTUCZNEGO NEURONU (McCULLOCH'A I PITTS'A 1943)



- **Wejście**
 - n stanów wejściowych x_1, \dots, x_n
 - stany mogą być cyfrowe lub analogowe
- **Wyjście**
 - 0 lub 1
- **Parametry perceptronu**
 - n wag połączeń $w_1, \dots, w_n \in \mathfrak{R}$ (wagi synaptyczne)
 - wartość progową (bias) $b \in \mathfrak{R}$




SZTUCZNY NEURON – ZASADA DZIAŁANIA



- Do każdego i -tego wejścia przypisana jest **waga** w_i
- Dla danych stanów wejściowych x_1, \dots, x_n liczymy **sumę ważoną**:
$$net = \sum_{i=1}^n w_i x_i + b$$
- Jeżeli $net \geq 0$, to ustawiamy wyjście $y = 1$, zaś w przeciwnym przypadku ustawiamy $y = 0$



JAK OPISAĆ PERCEPTRON?




- **Wejścia**
- **Zbiór wag** $w_1, \dots, w_n \in \mathbb{R}$
- **Wartość progowa (bias)** $b \in \mathbb{R}$
- **Funkcja aktywacji:** funkcji, według której obliczana jest wartość wyjścia neuronów sieci neuronowych



FUNKCJE AKTYWACJI - DYSKRETNE


Progowa unipolarna

$$f(net) = \begin{cases} 1 \Leftrightarrow net \geq 0 \\ 0 \Leftrightarrow net < 0 \end{cases}$$



Progowa bipolarna


$$f(net) = \begin{cases} 1 \Leftrightarrow net \geq 0 \\ -1 \Leftrightarrow net < 0 \end{cases}$$



FUNKCJE AKTYWACJI - CIĄGŁE


Sigmoidalna unipolarna

$$f(net) = \frac{1}{1 + e^{-\lambda net}}$$



Sigmoidalna bipolarna
(tangens hiperboliczny)

$$f(net) = \frac{2}{1 + e^{-\lambda net}} - 1$$




Funkcja liniowa : $f(net) = a.net + b$

„Obcięta” funkcja liniowa:
$$f(net) = \begin{cases} -1 & net \leq -1 \\ net & -1 < net < 1 \\ 1 & 1 \leq net \end{cases}$$







INTERPRETACJA GEOMETRYCZNA (NEURON DYSKRETNY)

- **Równanie perceptronowe:**
 $w_1x_1 + w_2x_2 + \dots + w_nx_n + b = 0$
- Równanie perceptronu można potraktować jako równanie prostej (ogólnie: hiperpłaszczyzny w przestrzeni n -wymiarowej).
- Punkty leżące nad ową prostą klasyfikujemy jako **1**, zaś pozostałe jako **0**.
- **Quiz:** Jak interpretować neuron ciągły (z sigmoidalną funkcją aktywacji)?




CO POTRAFI PERCEPTRON?

Pojedynczy perceptron potrafi odróżniać zbiorów **liniowo separowalnych**.



CZEGO NIE POTRAFI PERCEPTRON?

- Pojedynczy perceptron nie potrafi odróżniać zbiorów **nieseparowalnych liniowo**, np. funkcji XOR.
- Odkrycie tych ograniczeń (1969) na wiele lat zahamowało rozwój sieci neuronowych.





ZADANIE PERCEPTRONU

- Zadaniem pojedynczego perceptronu jest jedynie:
 - przetwarzanie jednostkowych informacji
 - podejmowanie prostych decyzji
 - przekazywanie wyników sąsiadom
- Dopiero w połączeniu z innymi węzłami uzyskuje się zdolność podejmowania złożonych decyzji




ZADANIE PERCEPTRONU ARCHITEKTURY SIECI NEURONOWYCH

- Sieć jednokierunkowa **jednowarstwowa**
- Sieć jednokierunkowa **wielowarstwowa**
 - Uogólnienie perceptronu Rosenblatta
 - Funkcja aktywacji nieliniowa (sigmoidalna)




ARCHITEKTURY SIECI NEURONOWYCH

- Sieć rekurencyjna
jednowarstwowa



- Sieć rekurencyjna
z jedną ukrytą warstwą
Sieć Hopfielda



UCZENIE PERCEPTRONU

- Sposób działania perceptronu (wartości wag) w praktycznych problemach nie jest ustawiany ręcznie, tylko wyuczany na podstawie przykładów.
- Potrzebujemy zarówno metody uczenia jednego neuronu, jak i procedury obejmującej całą sieć.



GRUPY ALGORYTMÓW UCZĄCYCH

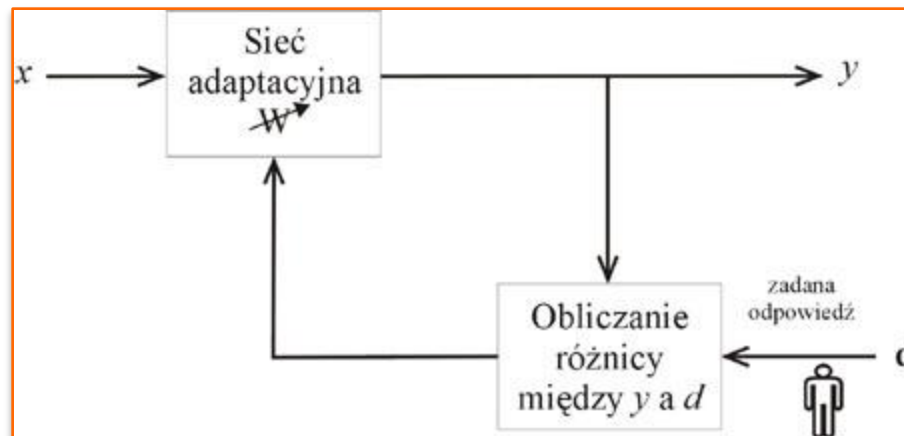
- Nadzorowane (z nauczycielem)
- Bez nadzoru (bez nauczyciela)



UCZENIE PERCEPTRONU Z NAUCZYCIELEM

- **Wejście:**
 - Ciąg przykładów uczących ze znanymi odpowiedziami: $\{(\mathbf{x}_1, d_1), (\mathbf{x}_2, d_2), \dots, (\mathbf{x}_n, d_n)\}$
- **Wyjście:** Wagi $\{w_1, w_2, \dots, w_n\}$
- **Celem:** Zminimalizować funkcję błędu:

$$\text{Error} = \sum_k (d_k - y_k)^2$$



REGUŁY ADAPTACJI WAG

- Przykład uczący:

$$\mathbf{x} = [x_1, x_2, \dots, x_n, 1]$$

- Żądana odpowiedź:

$$\mathbf{d} = [d_1, d_2, \dots, d_m]$$

- Reguła perceptronowa**
(dla neuronów dyskretnych):

$$\Delta w_{ij} = \eta \cdot (d_i - y_i) \cdot x_j$$

$$b_j = \eta \cdot (d_i - y_i)$$

η : współczynnik uczenia


- Reguła Delta**

(dla neuronów dyskretnych):

$$\Delta w_{ij} = \eta \cdot (d_i - y_i) \cdot f'(net_i) x_j$$

$$b_j = \eta \cdot (d_i - y_i) f'(net_i)$$

$f'(net_i)$: pochodna funkcji aktywacji i-tego neuronu



ALGORYTM UCZENIA PERCEPTRONU (REGUŁA PERCEPTRONOWA)

1. Inicjalizuj wagi sieci jako niewielkie liczby losowe;
2. Dla kolejnego przykładu uczącego \mathbf{x}
 - oblicz wektor sygnałów wyjściowych \mathbf{y}
 - wartość błędu

$$\delta_k = d_k - y_k$$

3. Oblicz zmianę wag $\Delta \mathbf{w}$:

$$\Delta \mathbf{w}_k(t) = \eta \delta_k \mathbf{x}$$

4. Uaktualnij wektor wag $\mathbf{w}(t+1)$:



$$\mathbf{w}_k(t+1) = \mathbf{w}(t) + \Delta \mathbf{w}(t);$$

5. Powtarzaj kroki 1-4 dopóki błąd nie osiągnie akceptowalnej wartości.



ALGORYTM UCZENIA PERCEPTRON - PRZYKŁAD

x_1	x_2	Output
1.0	1.0	1
9.4	6.4	-1
2.5	2.1	1
8.0	7.7	-1
0.5	2.2	1
7.9	8.4	-1
7.0	7.0	-1
2.8	0.8	1
1.2	3.0	1
7.8	6.1	-1




Funkcja aktywacji:

$$y = \begin{cases} 1 & \Leftrightarrow \sum w_i x_i + b \geq 0 \\ -1 & \text{otherwise} \end{cases}$$



UCZENIA PERCEPTRON -PRZYKŁAD



- Niech początkowe wagi: $w_1=1, w_2=1, b=1$

- $net_1 = x_1w_1 + x_2w_2 + b = 1+1+1=3 \Rightarrow$

$$y_1 = f(net) = 1$$

- Pierwszy przykład jest dobry, ale drugi nie jest, bo

$$net_2 = x_1w_1 + x_2w_2 + b = 9.4+6.4+1=16.8 \Rightarrow$$

$$y_2 = f(net_2) = 1$$

- Uaktualizuj wagi: ($\eta = 1$)

$$w_1 := w_1 + \eta(-1-1) \quad 9.4 = 1-18.8 = -17.8$$

$$w_2 := w_2 + \eta(-1-1) \quad 6.4 = 1-12.8 = -11.8$$

$$b := b + \eta(-1-1) = 1-2 = -1$$

- Zatem

$$w_1 = -17.8.$$

$$w_2 = -11.8$$

$$b = -1$$

- Drugi przykład jest dobry, sprawdź dalej trzeci przykład...

x_1	x_2	Output
1.0	1.0	1
9.4	6.4	-1
2.5	2.1	1
8.0	7.7	-1
0.5	2.2	1
7.9	8.4	-1
7.0	7.0	-1
2.8	0.8	1
1.2	3.0	1
7.8	6.1	-1

PYTANIA SPRAWDZAJĄCE:

1. Czym się charakteryzuje prosty perceptron?
2. Gdzie jest realizowana funkcja aktywacji i jakie są typy funkcji aktywacji?
3. Reguła perceptronowa (delta) do uczenia dyskretnych (ciągłych) perceptronów

